贾天瑞

(+86)18614269237 | 北京市 | j18614269732@163.com

基本信息

- 求职意向：大模型算法实习生　研究方向：深度学习、大模型
- 出生年月：2002.12　性别：男　所在地区：北京

教育经历

北京理工大学 | 数学与应用数学 / 硕士研究生（在读）　2024.09—至今

北京理工大学 | 数学与应用数学 / 学士　2020.09—2024.06

- **主修课程**：系统学习机器学习、深度学习、数学等课程。
- **荣誉奖项**：北京理工大学奖学金（一等奖、二等奖）；全国大学生数学竞赛省级三等奖；全国大学生英语竞赛三等奖。

技术能力与特长

- **大模型算法与微调**：深入理解 **Transformer** 架构及 Attention 机制；熟练掌握 **SFT**、**LoRA**、**P-Tuning v2**、**Adapter** 等微调技术；具备 **Qwen**、**LLaMA**、**GLM** 等主流模型的微调与推理优化经验。
- **RAG 与 Agent 开发**：熟练掌握 **RAG 全链路开发**（文档解析、分块策略、混合检索、Rerank）；掌握 **LangChain**、**LlamaIndex** 框架；掌握 **Function Call**、**ReAct**、**CoT** 等 Agent 规划策略；熟悉 **Milvus**、**Faiss** 向量数据库及 **Neo4j** 图数据库应用。
- **多模态与前沿架构**：熟悉 **Diffusion Model**（含 **Rectified Flow**）原理及应用；具备音频信号处理（**EMD**、**频谱分析**）及多模态融合（**EEG+Audio+Text**）建模经验。
- **框架与工程化**：熟练掌握 **PyTorch** 与 **GBDT** 等机器学习模型，熟悉 **C++/MATLAB**；掌握模型压缩（**INT8/INT4 量化**、**剪枝**、**蒸馏**）；熟悉 Linux 环境开发与 **Docker** 容器化部署。
- **英语读写能力**：CET-4 588，CET-6 542；具备较强的英文论文阅读与写作能力。

实习经历

理想汽车：**车载音乐个性化推荐检索排序系统** | 大模型实习生 / 智能汽车群组-软件本体-理想同学-理想同学智能体部-工具生态组　2025.02—至今

- **项目描述**：面向车机端“用户画像 + 车况上下文 + Query”的音乐推荐场景，搭建 **双塔召回** → **策略过滤** → **Reranker 精排**的两阶段链路，实现低延迟、高精准的个性化推荐。
- **数据闭环构建**：从零到一搭建端到端数据流，整合 **11.86 万**用户画像、**526 万**播放行为及 **21.44 万**歌曲库，构造约 **100 万**训练对；设计 **InfoNCE/in-batch softmax** 损失，引入曝光负样、随机负样及 **Hard Negative** 挖掘策略，提升模型判别能力。
- **特征工程与标准化**：固化 Query/Item 文本 Schema（字段顺序、连续特征分桶、缺失值策略），提升训练与检索一致性；统一 Embedding 模型（**bge-m3 / Qwen3-Embedding**），批量生成 **21 万** + 歌曲向量并构建 ANN 索引缓存。
- **检索增强与重排序**：引入 LLM（**Qwen2.5-3B**）进行 Query/Item 文本改写增强，构建 Top200 文本对并使用 **bge-reranker-v2-m3** 重排序输出 Top10；建立 **Recall@K**、**MRR**、**NDCG@K** 及分场景分桶评估体系，完成 Badcase 分析闭环。
- **阶段性效果（离线/回放口径）**：相比基线模型，NDCG@10 提升 6.8%，MRR@10 提升 9.3%，Recall@200 提升至 78.4%，有效增强召回覆盖能力构建千万级向量索引（Faiss IVF-PQ），召回延迟控制在 100ms 内

项目经历

NeurIPS 2025 Google Code Golf **锦标赛** | **自动化代码压缩** Agent | 核心开发者　2025.09—2025.11

- **项目描述**：针对 ARC-GEN 任务构建自动化代码压缩与验证框架，最终获得全球第 **13** 名（银牌区第 **1** 名）。
- **Agent 闭环设计**：设计基于 ARC-GEN 集成 Codex Agent 的多智能体协作流程，实现“候选解生成 → 正确性校验 → 最优解筛选”的自动化闭环，累计完成 **2000+** 次自动迭代。

- **提示工程与压缩策略**：设计 **zlib + Base85** 通用压缩壳并结合 Prompt 工程压缩 solver 代码，驱动 **DeepSeek**、**GPT-5**、**Qwen** 等多模型多轮代码逻辑重构。
- **工程落地**：搭建基于 **GitHub Actions** 的 CI/CD 流水线，实现 PR 自动合并、版本管理及 Kaggle API 自动提交。

EduRAG ｜**基于 RAG 的教育场景智能问答系统**｜独立负责人 2025.03—2025.08

- **项目描述**：从 0 到 1 构建面向教育场景的智能问答系统，整合课程、政策等多源异构知识，实现高准确率自动应答。
- **检索增强架构**：基于 **Milvus** 构建向量索引，设计 PDF/Word/PPT 多格式文档清洗与 OCR 提取流水线，累计处理 **50 万 +** 知识片段；实施稀疏 + 稠密混合检索与 **BGE-Reranker** 重排序策略，提升长尾知识召回效果。
- **意图识别与生成**：基于 **Sentence-BERT** 构建意图分类模型（**F1=91.27%**）；设计历史对话融合与 **HyDE** 的 Query 重写模块；利用 **Qwen2.5-7B** 进行指令微调，控制回答格式与幻觉。
- **部署与评估**：构建 **RagAS** 自动评估（答案相关性 **0.91**，忠实性 **0.93**），基于 **1000** 条标注测试集验证整体准确率 **89.74%**；通过 **FastAPI** 封装服务并上线，自动应答率达 **81.56%**。

科研成果

- **[BSPC, Q2 ｜已录用｜第一作者] Breaking Through Data Scarcity: A Novel Diffusion Model Approach for Snoring Sound Augmentation**
  创新点：提出基于扩散模型的原始波形增强框架，并首次将 **Rectified Flow** 应用于音频生成；构建端到端模型 **RFSSDiff**，并设计针对类别不平衡的数据增强策略。
  成果：在 MPSSC 中将 UAR 提升至 **62.5%**（**+5.8%**），显著增强低资源条件下分类性能。
- **[INTERSPEECH 2025, CCF-C ｜主要贡献者] Exploring EMD for Sensing the Sound of Silence: Mice Autism Detection via Ultrasonic Vocalization**
  创新点：构建融合 **EMD** 与频谱图的多分支网络，实现超声叫声的多尺度建模与可解释特征提取。
  成果：验证高频 IMF1 为区分 ASD/WT 的关键声学标志；在 MADUV 上明显优于基线（**p<0.05**）。
- **[IEEE JBHI, Q1 TOP ｜共同一作｜在投] Robust EMG Forecasting for IoT Healthcare via Adaptive Mapping & Normalization-Free Transformer**
  创新点：提出基于 **MNN** 的 EMG 分解映射，并结合 **RLP-RIME** 完成自动超参搜索；采用 **DyT** 实现无归一化时序建模。
  成效：R^2 指标平均提升 **15.5%**，推理延迟降低 **61.3%**，超越 TimeMixer 等 SOTA 模型。
- **[Pattern Recognition, Q1 TOP ｜学生二作｜准备投稿] Bayesian Knowledge-Guided Confidence-Aware Method for Depression Detection**
  创新点：提出 **BLADE** 框架，融合 LaBraM（EEG）与 Emo2Vec（Audio），引入贝叶斯不确定性与潜空间扩散机制。
  成效：在 MODMA 数据集取得 **100%** 被试级与 **88.12%** 样本级结果，多模态融合效果显著领先。

自我评价

- **数理基础扎实**：数学系科班出身，对深度学习背后的优化理论、概率统计有扎实理解，能快速复现顶会论文算法。
- **全栈算法能力**：具备从数据清洗、模型微调（SFT/RLHF）、RAG 构建到 Agent 开发、量化部署的全链路实战经验。
- **持续学习热情**：密切关注 LLM 前沿动态，具备良好的英文文献阅读与技术调研能力。
- **团队协作能力**：沟通顺畅，能在复杂任务中主动承担责任并推动项目进展。